

CS229-note1-学习心得

第一部分

线性回归

简介：

1.背景：地区 房间大小和价格 数据，推进如何执行监督学习，以及确定参数 θ 。

将 y 假设为关于 x 的线性函数， θ 代表拟合参数

于是：

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$

为了简单起见，假定 $x_0 = 1$

于是：

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x,$$

如何确定 θ ？

于是：

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

注：1/2参考方差

2.LMS算法-最小均方，也称为 Widrow-Hoff 学习规则，也即最小梯度下降

为了使 $J(\theta)$ 更小，直到我们希望收敛到使 $J(\theta)$ 最小化的 θ 值

于是：

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta).$$

注： α 称为学习率。这是一种非常自然的算法，它会在 J 的最陡下降方向上重复迈出一步

公式2-1

假设我们有一个训练实例 (x, y) ，我们需要计算出右侧的偏导数

于是：

$$\begin{aligned} \frac{\partial}{\partial \theta_j} J(\theta) &= \frac{\partial}{\partial \theta_j} \frac{1}{2} (h_{\theta}(x) - y)^2 \\ &= 2 \cdot \frac{1}{2} (h_{\theta}(x) - y) \cdot \frac{\partial}{\partial \theta_j} (h_{\theta}(x) - y) \\ &= (h_{\theta}(x) - y) \cdot \frac{\partial}{\partial \theta_j} \left(\sum_{i=0}^n \theta_i x_i - y \right) \\ &= (h_{\theta}(x) - y) x_j \end{aligned}$$

公式 2-2

接着，结合公式2-1和2公式-2

于是：

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}.$$

注：LMS更新规则（LMS代表“最小均方”），也称为 Widrow-Hoff 学习规则。

如果在拟合过程中，我们的预测值和实际值有较大出入，以下是两种解决方法：

First.对于包含多个训练集，替换为以下算法，重复直到收敛：

Repeat until convergence {

$$\theta_j := \theta_j + \alpha \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)} \quad (\text{for every } j).$$


}

注：求和部分为 $\partial J(\theta)/\partial \theta_j$ (for the original definition of J).

- 此方法被称为**批梯度下降**，每一步都扫描整个**训练集**的每个实例
- 此方法受**局部极小值**影响大，但是**线性回归问题**只有一个全局最优值，因此此梯度下降总是**收敛**
- 假设 **学习率** α 不太大


下面是对比两种方法的直观图：

U



The ellipses shown above are the contours of a quadratic function. Also shown is the trajectory taken by gradient descent, which was initialized at (48,30). The x 's in the figure (joined by straight lines) mark the successive values of θ that gradient descent went through.

梯度下降实例



If the number of bedrooms were included as one of the input features as well, we get $\theta_0 = 89.60$, $\theta_1 = 0.1392$, $\theta_2 = -8.738$.

批梯度下降实例

考虑以下算法：

```
Loop {  
    for i=1 to m, {  
         $\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$     (for every  $j$ ).  
    }  
}
```

- 根据**单个训练样例**相关误差梯度更新参数
 - **随机梯度下降**
 - 不用每次都扫描**整个训练集**
 - 更快 **接近 θ 最小值**，可能永远无法到达最小值，在**最小值附近振荡**
-

3.正规方程

3.1矩阵导数

3.2最小二乘再访

4.概率解释

5.局部加权线性回归

第二部分

分类和逻辑回归